Analisi Matematica e Architetturale per il Dimensionamento Hardware di Sistemi di Intelligenza Artificiale Agenti

L'adozione di sistemi di Intelligenza Artificiale (IA) generativa all'interno di ambienti di produzione aziendale ha superato la mera fase sperimentale, contrassegnata da semplici interazioni di tipo chat (stateless), per approdare a un paradigma architetturale immensamente più complesso: i flussi di lavoro "agenti" (agentic workflows). A differenza delle architetture tradizionali, i sistemi agenti operano in modo proattivo e autonomo, eseguendo catene di ragionamento multi-step, richiamando strumenti esterni (tool use, come API o database), auto-correggendo i propri errori e, fondamentalmente, mantenendo in memoria un vasto e crescente contesto di stati intermedi.[1] Questa profonda evoluzione comportamentale trasforma radicalmente l'equazione dell'ingegneria e del dimensionamento hardware. Il calcolo infrastrutturale non si limita più alla semplice allocazione dei pesi del modello all'interno della memoria video (VRAM), ma impone un'analisi termodinamica, computazionale e probabilistica rigorosa. Diventa imperativo gestire l'espansione esponenziale della cache delle attenzioni, limitare la latenza derivante dalla varianza estrema dei tempi di servizio e calcolare meticolosamente i requisiti termici ed energetici per garantire la stabilità operativa.[2]

Il presente rapporto esplora in modo esaustivo e dettagliato la matematica sottostante la creazione di infrastrutture hardware dedicate all'inferenza di Large Language Models (LLM). Applicando modelli teorici avanzati, l'analisi si concentra sulla risoluzione matematica di due scenari operativi specifici: l'implementazione e il dimensionamento hardware per sostenere il peggiore dei casi (worst-case scenario) di 20 utenti concorrenti che utilizzano agenticamente un modello da 70 miliardi (70B) di parametri, e la medesima infrastruttura declinata per un modello da 8 miliardi (8B) di parametri, comunemente definito "mini agente".

Fondamenti Matematici dell'Inferenza nei Modelli Transformer

L'inferenza di un modello linguistico basato su architettura Transformer, come i modelli della famiglia Llama 3.1, si divide strutturalmente in due fasi computazionalmente distinte. La prima è la fase di *prefill*, in cui il modello elabora i token del prompt iniziale in parallelo per popolare la memoria interna. La seconda è la fase di *decode*, in cui il modello genera in modo autoregressivo il token successivo, uno alla volta, basandosi sul contesto accumulato.[4] La pianificazione hardware richiede la modellazione matematica precisa di tre componenti fondamentali della memoria del sistema: i pesi statici del modello, le attivazioni temporanee dei tensori e, elemento di gran lunga più critico nei sistemi agenti, la cache Key-Value (KV Cache).[5]

Modello Matematico dei Requisiti di Memoria Statica

La memoria statica rappresenta lo spazio fisico in gigabyte necessario per ospitare i parametri del modello all'interno della VRAM della scheda grafica. Questo valore dipende linearmente da due fattori: la dimensione pura del modello (il numero di parametri) e il livello di precisione numerica (quantizzazione) utilizzato per rappresentare i pesi durante i calcoli tensoriali.[7]

L'equazione fondamentale per stimare la memoria dei parametri è definita come segue:

$$M_{pesi} = P \times \left(\frac{Q}{8}\right) \times (1 + O)$$

Dove la variabile M_{pesi} indica la memoria richiesta in gigabyte (GB). La variabile P rappresenta il numero totale di parametri del modello, espresso in miliardi. La variabile Q indica la precisione in bit del formato numerico scelto (ad esempio, 32 per FP32, 16 per FP16 o BF16, 8 per INT8 o FP8, e 4 per INT4). La divisione del valore Q per 8 è una semplice conversione informatica da bit a byte. Infine, la variabile O rappresenta un moltiplicatore di overhead percentuale (solitamente tra il 10% e il 20%), necessario per l'allocazione del framework CUDA e dei buffer di frammentazione della memoria.[7]

Per ambienti di produzione aziendale che richiedono alte capacità di ragionamento agentico senza alcun degrado delle prestazioni logiche e analitiche, l'uso di una quantizzazione inferiore a 8 bit (come i formati INT4) è tipicamente sconsigliato. La compressione eccessiva dei pesi causa un deterioramento della perplessità del modello, limitandone la capacità di eseguire catene di pensiero (Chain-of-Thought) complesse.[9] Pertanto, lo standard industriale di riferimento per preservare le capacità logiche di un agente rimane l'FP16 (Half Precision) o il BF16 (Brain Floating Point), che richiedono esattamente 2 byte per ogni parametro.[4] L'avvento di architetture hardware moderne come NVIDIA Hopper (H100) ha introdotto il supporto nativo per l'FP8, che dimezza il footprint di memoria mantenendo un'accuratezza paragonabile al formato a 16 bit, offrendo un eccellente compromesso matematico.[11]

Matematica della Cache Key-Value (KV Cache)

Nei complessi sistemi agenti, il modello di intelligenza artificiale deve ricordare non solo il prompt originale fornito dall'utente, ma anche le risposte precedentemente generate, gli immensi output testuali derivanti dall'uso di strumenti esterni (come la lettura di database o l'esecuzione di codice Python), e i passaggi logici intermedi generati autonomamente dal modello stesso.[3] Questo processo richiede il mantenimento in memoria dei tensori "Key" (Chiave) e "Value" (Valore) per ogni singolo token elaborato nella sequenza. Senza questa memorizzazione, il modello dovrebbe ricalcolare per intero l'intera matrice di attenzione a ogni nuovo token generato, portando a tempi di inferenza inaccettabili.[4]

La dimensione della KV Cache per un singolo token non è un valore arbitrario, ma è strettamente determinata dalle specifiche architetturali del layer Transformer del modello. L'equazione esatta per il calcolo della KV Cache per singolo token è:

$$M_{KV_token} = 2 \times n_{layers} \times n_{KV_heads} \times d_{head} \times b_{precision}$$

In questa equazione matematica, il moltiplicatore iniziale pari a 2 rappresenta la necessità di memorizzare le due matrici tensoriali distinte: la matrice Key e la matrice Value.[4] La variabile n_{layers} indica il numero totale di strati (blocks) sovrapposti all'interno del Transformer. La variabile n_{KV_heads} denota il numero di teste di attenzione dedicate specificamente alla gestione dei tensori Key e Value. È importante sottolineare che le architetture LLM moderne, inclusa la famiglia Llama 3.1, utilizzano una tecnica denominata *Grouped-Query Attention* (GQA). La GQA riduce significativamente il numero di teste KV rispetto al numero di teste Query, condividendo una singola testa KV tra più teste Query. Questa scelta architetturale è stata introdotta matematicamente proprio per ottimizzare e contenere l'uso esplosivo della memoria durante l'inferenza di lunghi contesti.[15] La variabile d_{head} rappresenta la dimensionalità vettoriale di ogni singola testa di attenzione, un valore che è tipicamente calcolato dividendo la dimensione totale del modello (d_{model}) per il numero totale di teste di attenzione Query (n_{heads}).[4] Infine, $b_{precision}$ è il numero di byte richiesti dal formato di quantizzazione scelto (ad esempio, 2 byte per FP16).[4]

Una volta stabilita la dimensione in byte per un singolo token, è necessario calcolare come questa memoria scali in base all'utilizzo. La memoria totale della KV Cache dinamica scala linearmente con il numero di utenti concorrenti simultanei (U) e con la lunghezza massima del contesto misurata in token (L):

$$KV_{totale} = M_{KV_token} \times U \times L$$

Nei casi d'uso agenti aziendali, il contesto L si espande in modo drammatico e rapidissimo. Un agente che analizza documenti legali o file di log di sistema può facilmente riempire finestre di contesto da 32.000 a 128.000 token in poche interazioni. Di conseguenza, il termine KV_{totale} supera spesso la dimensione statica dei pesi del modello, diventando il principale collo di bottiglia fisico e finanziario per la progettazione dell'architettura hardware.[2]

Memoria delle Attivazioni e Overhead dei Framework Agenti

Oltre ai pesi statici e alla KV Cache cumulativa, i calcoli tensoriali richiedono una porzione di

memoria effimera nota come buffer delle attivazioni. Le memorie di attivazione temporanee immagazzinano i calcoli intermedi necessari durante il *forward pass* all'interno della rete neurale. La matematica che governa questa memoria fluttua in base all'architettura e al parallelismo delle richieste. La formula approssimativa per calcolare il buffer di attivazione è:

$$M_{act} = B \times L \times d_{model} \times n_{layers} \times 2 \text{ byte}$$

Dove B rappresenta il batch size (numero di sequenze processate in parallelo) e L la lunghezza della sequenza. A differenza della KV Cache, la memoria di attivazione ha un ciclo di vita breve all'interno dell'elaborazione del singolo step, ma scala anch'essa linearmente con il batch size e proporzionalmente con la profondità del modello.[5] Sebbene rappresenti generalmente solo il 5-10% del budget totale di memoria durante l'inferenza (a differenza del training dove è preponderante), la sua omissione nei calcoli di dimensionamento causa frequenti e improvvisi errori di "Out of Memory" (OOM) nei server di produzione, causando l'interruzione dei servizi aziendali.[6]

A questi vincoli a livello di GPU si aggiunge il severo impatto generato dai framework software agentici eseguiti a livello di host (CPU e RAM di sistema). Strumenti industriali standard come LangChain, CrewAI, AutoGen o Strands richiedono un tracciamento continuo e persistente degli stati in memoria, la gestione parallela di thread di esecuzione asincroni, il buffering dei dati recuperati dai database vettoriali e l'orchestrazione delle API esterne.[2] Questo complesso ecosistema si traduce in un impiego di System RAM (la memoria della scheda madre, distinta dalla VRAM delle GPU) significativamente maggiore rispetto ai semplici script di inferenza di base. Il buffering inefficiente o la manipolazione di array massivi da parte di questi framework rende tassativo un sovradimensionamento della RAM dell'host, al fine di evitare il paging o lo swapping su disco solido, un evento che distruggerebbe istantaneamente i vantaggi di latenza offerti dalle GPU di classe enterprise.[2]

Teoria delle Code, Concorrenza e il Peggiore dei Casi

La richiesta aziendale prevede il calcolo ingegneristico di un hardware in grado di sostenere il "peggiore dei casi" (worst-case scenario) per 20 utenti concorrenti. In un paradigma agentico, la concorrenza assume un significato peculiare: non significa semplicemente ricevere 20 chiamate API web isolate nel medesimo istante, ma significa gestire 20 flussi di lavoro in parallelo che operano in *loop* di ragionamento prolungati, generando autonomamente token per svariati minuti senza interruzione.[1]

Il comportamento del server di inferenza sottoposto a tale stress può essere modellato matematicamente attraverso i principi della Teoria delle Code, specificamente utilizzando un modello $M/G/1$ o $M/G/k$. In questo modello stocastico, si assume che gli arrivi delle richieste utente seguano una distribuzione di Poisson (indicata dalla lettera M, per Markoviana), i tempi di servizio (la generazione effettiva dei token) seguano una distribuzione generale (G) a

causa della variabilità intrinseca ed estrema delle risposte degli agenti, e le GPU aggregate mediante tensor parallelism fungano da singolo server o da k server paralleli.[21]

Sia la variabile λ il tasso medio di arrivo delle interazioni (richieste in ingresso al secondo) e la variabile μ il tasso medio di servizio offerto dal sistema hardware. Il tempo di servizio, denotato dalla variabile aleatoria S, possiede una varianza altissima nei sistemi agenti, indicata come $Var(S)$. L'utilizzazione del sistema, ovvero la frazione di tempo in cui l'hardware è attivamente occupato, è definita dalla seguente equazione:

$$\rho = \frac{\lambda \cdot E}{k}$$

Il teorema di Pollaczek-Khinchine per la determinazione della latenza di coda media (W_q) in un sistema $M/G/1$ stabilisce un principio fondamentale per l'ingegneria del software AI: la latenza esplode asintoticamente quando l'utilizzazione ρ si avvicina al 100%, e tale esplosione è direttamente proporzionale alla varianza del tempo di servizio:

$$W_q = \frac{\lambda \left(Var(S) + E^2\right)}{2(1-\rho)}$$

Poiché l'intelligenza artificiale agentica possiede una varianza intrinseca elevatissima per definizione—un task di routing può risolversi emettendo 10 token in una frazione di secondo, mentre un task di scrittura di codice software o analisi dati può richiedere 10.000 token elaborati in background su molteplici iterazioni [22]—il termine $Var(S)$ è enorme. Di conseguenza, il sistema deve essere matematicamente sovradimensionato per garantire che l'utilizzazione teorica ρ rimanga ben al di sotto della saturazione critica (tipicamente mantenuta tra 0.4 e 0.7) per preservare i service-level objectives (SLO) di latenza aziendale.[24]

La strategia matematica per calcolare l'hardware nel peggiore dei casi con 20 utenti prevede quindi di abbandonare l'ottimizzazione probabilistica media e adottare un'allocazione statica della massima memoria possibile. Ciò significa riservare memoria per un Batch Size costante $B = 20$ e pre-allocare contemporaneamente la lunghezza massima del contesto operativamente consentita dal sistema per ogni singolo utente. Fissando un limite operativo stabile di $L = 32.768$ token (32K), si assicura uno spazio sufficiente per gestire catene logiche complesse, inserimento di documenti aziendali via Retrieval-Augmented Generation (RAG) e cronologia estesa degli strumenti, senza incorrere nei crash sistemici tipici dei picchi di

traffico non gestiti.[5]

Intensità Aritmetica e Colli di Bottiglia dell'Infrastruttura

Per determinare l'efficacia dell'hardware, il calcolo dello spazio di archiviazione VRAM deve essere affiancato alla modellazione delle prestazioni computazionali. Il parametro ingegneristico chiave in questo dominio è l'Intensità Aritmetica (I), definita come il rapporto tra il numero di operazioni matematiche in virgola mobile (FLOPs) eseguite dai core di calcolo e il numero totale di byte trasferiti dalla memoria ad alta larghezza di banda (HBM) verso i registri dei processori.[4]

$$I = \frac{\text{Operazioni Eseguite (FLOPs)}}{\text{Accessi in Memoria Effettuati (Bytes)}}$$

Ogni pezzo di silicio progettato per l'accelerazione AI possiede un proprio rapporto teorico Ops:Byte. Ad esempio, prendendo in esame la GPU standard di settore NVIDIA H100 SXM, questa fornisce circa 989 TFLOPs di potenza bruta in formato FP16, supportata da una larghezza di banda di memoria di 3.35 TB/s. Il rapporto intrinseco dell'hardware risulta quindi essere di circa 295 Ops/Byte.[11]

Durante la complessa fase di decode autoregressivo, per la generazione di ogni singolo nuovo token, il sistema è costretto a leggere dalla VRAM l'interezza dei pesi del modello (decine o centinaia di gigabyte) e l'intera KV Cache associata al contesto in corso, al fine di eseguire calcoli che, proporzionalmente, sono estremamente semplici e veloci. Questa asimmetria fa sì che l'intensità aritmetica dell'inferenza LLM per un singolo utente sia tipicamente bassissima (spesso inferiore a 10 Ops/Byte), posizionando inequivocabilmente il carico di lavoro nel dominio *Memory-Bound* (limitato e strangolato dalla larghezza di banda della memoria, non dalla potenza di calcolo).[4]

Per mitigare questo inevitabile collo di bottiglia fisico, i framework di inferenza aziendali (come vLLM o TensorRT-LLM) implementano il *Continuous Batching*. Questa tecnica raggruppa le richieste di molteplici utenti, caricando i giganteschi pesi del modello dalla memoria una sola volta per ciclo di clock e riutilizzandoli per calcolare simultaneamente i token successivi di tutti gli utenti nel batch. Aumentando la variabile della concorrenza ($U = 20$), si aumenta matematicamente l'intensità aritmetica dell'algoritmo, innalzando l'efficienza complessiva dell'hardware fino a sfruttare pienamente i Tensor Cores disponibili.[4] Questo spiega perché i requisiti di memoria esplodono con gli agenti concorrenti: la memoria è il prezzo da pagare per sbloccare il throughput di calcolo.

Dimensionamento Hardware Completo per il Modello da 70B di Parametri

Il modello Llama 3.1 70B rappresenta attualmente una delle architetture open-weights più performanti, sofisticate e diffuse per l'esecuzione di complessi flussi di lavoro agenti di livello enterprise.[15] Le sue caratteristiche strutturali interne sono documentate rigorosamente e consentono l'applicazione precisa delle formule matematiche precedentemente esposte per un dimensionamento millimetrico.

Parametri Architetturali Llama 3.1 70B

Per eseguire i calcoli, è essenziale estrarre le metriche architetturali dalla configurazione ufficiale del modello. I dati strutturali fondamentali sono i seguenti:

Parametro Architetturale	Valore Specifico per Llama 3.1 70B
Parametri Totali (P)	~70,6 Miliardi
Livelli Transformer (n_{layers})	80 [5]
Teste di Attenzione Query (n_{heads})	64 [30]
Teste di Attenzione KV (n_{KV_heads})	8 (tramite tecnologia GQA) [31]
Dimensione Nascosta Modello (d_{model})	8.192 vettori [30]
Dimensione Singola Testa (d_{head})	128 (calcolato come $8192/64$)
Precisione Ottimale ($b_{precision}$)	FP16 o BF16 (2 byte per parametro) [7]

Calcolo VRAM: Pesi, KV Cache e Totale per 20 Utenti (Worst-Case)

Il primo passo consiste nell'allocazione della memoria statica dei pesi. Applicando l'equazione per i pesi in precisione FP16 (senza degradazione INT8 o INT4):

$$M_{pesi} = 70.6 \times 10^9 \times \frac{16}{8} \approx 141,2 \text{ GB}$$

Il modello allo stato puro, senza elaborare alcuna informazione, necessita di poco più di 140 GB di VRAM ininterrotta solamente per risiedere nella memoria del server.[5]

Il secondo passo è la quantificazione della memoria dinamica della KV Cache. Sostituendo i valori architetturali nella formula del singolo token otteniamo:

$$M_{KV_token} = 2(\text{Key e Value}) \times 80 \times 8 \times 128 \times 2 \text{ byte} = 327.680 \text{ byte/token}$$

Questo valore equivale a circa $0,3125$ Megabyte per ogni singolo token immesso o generato dal modello a 70B.[10]

Nello scenario aziendale worst-case esplicitamente richiesto, si devono servire 20 utenti concorrenti che operano simultaneamente. Stabilendo un limite operativo di sicurezza e stabilità per il contesto massimo pari a $L = 32.768$ token (32K), calcoliamo il requisito massimo garantito per un singolo agente:

$$KV_{utente} = 32.768 \text{ token} \times 0,3125 \text{ MB/token} = 10.240 \text{ MB} \approx 10,24 \text{ GB}$$

Moltiplicando per il carico di concorrenza massimo ($U = 20$), otteniamo la memoria totale dedicata esclusivamente a mantenere la lucidità del contesto per gli agenti:

$$KV_{totale} = 20 \times 10,24 \text{ GB} = 204,8 \text{ GB}$$

Nota tecnica: I modelli Llama 3.1 sono stati addestrati per supportare finestre di contesto estreme, fino a 128.000 token.[16] Se l'infrastruttura aziendale dovesse prevedere e pre-allocare il worst-case assoluto a 128K per tutti i 20 utenti simultaneamente, la richiesta di KV cache balzerebbe matematicamente a quasi 820 GB ($20 \times 39,06 \text{ GB}$).[14] Tale requisito polverizzerebbe le capacità di interi cluster commerciali standard. Pertanto, il limite logico di 32K token per iterazione rappresenta uno standard di produzione consolidato per applicazioni ad alta concorrenza.

Il terzo passo ingloba le memorie di attivazione temporanee per i passaggi in avanti (forward-pass) e i margini protettivi di frammentazione per l'allocatore di memoria (PyTorch/CUDA), che richiedono circa un 10% di tolleranza addizionale.[6] Includendo un overhead di circa 15 GB [5], si giunge al requisito di VRAM finale:

Requisito VRAM Totale Garantito (70B, 20 Utenti, 32K Contesto):

$$VRAM_{totale} = 141,2 \text{ GB (pesi)} + 204,8 \text{ GB (KV)} + 15 \text{ GB (overhead)} = 361 \text{ GB}$$

Selezione Architetturale Hardware e Dimensionamento RAM di Sistema

Un requisito inflessibile di oltre 360 GB di VRAM ad altissima larghezza di banda rende

fisicamente impossibile l'esecuzione su una singola scheda grafica. Si rende assolutamente necessaria l'implementazione del *Tensor Parallelism*, una complessa tecnica di calcolo distribuito che divide chirurgicamente le matrici dei pesi del modello e i calcoli di moltiplicazione orizzontalmente tra molteplici processori grafici. Questi processori devono essere interconnessi da ponti di rete specializzati a cortissimo raggio e altissima velocità per prevenire colli di bottiglia nei passaggi di stato.[33]

La disamina delle opzioni hardware enterprise disponibili sul mercato evidenzia marcate differenze:

Modello GPU	**Memoria**	**Larghezza di Banda**	**TFLOPs FP16**	**TDP**	**Considerazioni Architetturali**
NVIDIA H100 SXM	80 GB HBM3	3,35 TB/s	~989	700 W	Standard aureo. Interconnessione NVLink a 900 GB/s. Supporto nativo FP8.[11]
NVIDIA A100 SXM	80 GB HBM2e	2,04 TB/s	~312	400 W	Generazione precedente. Larghezza di banda limitata, throughput ridotto per agenti complessi.[26]
NVIDIA L40S PCIe	48 GB GDDR6	0,86 TB/s	~731	350 W	Memoria GDDR6 più lenta, interconnessione PCIe

					standard che penalizza il tensor parallelism esteso.[26]

Per soddisfare il fabbisogno di 360 GB, sarebbero matematicamente sufficienti 5 schede NVIDIA H100 o A100 (da 80 GB ciascuna). Tuttavia, il Tensor Parallelism soggiace a rigide regole topologiche: richiede imperativamente l'utilizzo di partizioni in potenze di 2 (2, 4, 8 GPU) per ottimizzare la simmetria geometrica del partizionamento delle matrici di attenzione e abbattere le penalità di latenza sulla rete NVLink interna al server.[34] Poiché 4 schede (320 GB) causerebbero inevitabilmente errori di tipo Out-Of-Memory (OOM) nello scenario peggiore, l'hardware minimo, stabile e professionale richiesto è un **singolo nodo server equipaggiato interamente con 8 GPU NVIDIA H100 80 GB** (raggiungendo un totale aggregato di 640 GB di VRAM).[33]

Questa configurazione sovradimensionata di quasi 280 GB rispetto al requisito teorico rigoroso offre uno strato di protezione vitale per assorbire picchi transitori di traffico non uniformi, o per garantire agilmente il supporto futuro verso contesti estesi ben oltre i 32K token per utente. La scelta della serie H100 rispetto alla serie A100 è giustificata non solo dalla capienza, ma dal throughput: la H100 offre prestazioni di generazione token da 2 a 4 volte superiori rispetto alla A100 in carichi di inferenza di modelli a 70 miliardi di parametri, un fattore che fa la differenza tra un agente che risponde in tempo reale e uno che produce timeout nei sistemi aziendali.[12]

Per quanto riguarda il dimensionamento della RAM di sistema (Host Memory), le specifiche sono altrettanto severe. Durante la fase di avvio (caricamento del modello dal disco NVMe alle GPU) o in caso di emergenze che richiedono un parziale *memory swapping* tra VRAM e RAM per scongiurare crash irrecuperabili, la RAM della scheda madre gestita dalle CPU (Intel Xeon o AMD EPYC) deve poter mappare tensori titanici. La regola matematica empirica consolidata nel settore detta che la capacità RAM debba essere misurata tra $1.2x$ e $1.5x$ la dimensione del modello in memoria.[9]

$$RAM_{sistema} \geq 1.5 \times 141,2 \text{ GB} = 211,8 \text{ GB}$$

In aggiunta, il peso computazionale dei framework agentici (orchestrazione, database vettoriali in-memory, thread pool) è sostenuto unicamente dall'host CPU. Per un server mastodontico dotato di 8 GPU H100, al fine di scongiurare in modo assoluto che la memoria di sistema diventi il collo di bottiglia durante i processi multi-threading ad altissima concorrenza, la prassi ingegneristica impone di equipaggiare il server con **almeno 512 GB, con una fortissima raccomandazione di scalare a 1 TB di RAM ECC DDR5**.[37]

Dimensionamento Hardware Completo per il Modello da 8B (Mini Agenti)

L'impiego di un modello ridotto da 8 miliardi di parametri (Llama 3.1 8B), pur comportando una decisa limitazione nelle capacità di ragionamento profondo rispetto al fratello maggiore, offre un'alternativa ingegneristica brillante. Abbatte drasticamente i requisiti di memoria per utente, mantenendo al contempo velocità e precisione operative eccellenti per task automatizzati specializzati, instradamento rapido di richieste (routing), generazione sintetica di dati e automazioni semplici.[10]

Parametri Architetturali e Calcolo VRAM per Llama 3.1 8B

L'estrazione dei parametri architetturali ufficiali per la variante da 8 miliardi evidenzia un design snello ma potente:

- **Parametri Totali (P)**: ~8,03 Miliardi.
- **Livelli Transformer (n_{layers})**: 32.[32]
- **Teste di Attenzione KV (n_{KV_heads})**: 8 (mantenimento dell'efficienza GQA).[14]
- **Dimensione Singola Testa (d_{head})**: 128.
- **Precisione Ottimale**: FP16 o BF16, risultante in un volume statico di circa **16 GB** per i soli pesi nudi.[10]

Applicando la medesima formula matematica precedente per derivare la dimensione della KV Cache associata a un singolo token elaborato dal modello a 8B otteniamo:

$$M_{KV_token} = 2 \times 32 \times 8 \times 128 \times 2 = 131.072 \text{ byte/token}$$

Il risultato equivale a esattamente $0,125$ Megabyte per token, una riduzione di quasi un terzo rispetto all'impronta lasciata dal modello a 70B.[14]

Trasportando questo valore nel medesimo scenario aziendale estremo, che prevede 20 utenti agenti concorrenti in elaborazione costante su finestre di contesto da 32.768 token, il fabbisogno di memoria dinamica cumulativa ammonta a:

$$KV_{totale} = 20 \times 32.768 \times 0,125 \text{ MB} = 81.920 \text{ MB} \approx 81,9 \text{ GB}$$

Sommando i pesi statici, la mostruosa cache dinamica e applicando un modesto overhead conservativo di circa 5 GB per le attivazioni del forward-pass di modelli piccoli e il tracciamento CUDA, si giunge al requisito finale:

Requisito VRAM Totale Garantito (8B, 20 Utenti, 32K Contesto):

$$VRAM_{totale} = 16 \text{ GB (pesi)} + 81,9 \text{ GB (KV)} + 5 \text{ GB (overhead)} = 102,9 \text{ GB}$$

Selezione Architetturale Hardware per 8B

Il requisito computato di poco più di 100 GB di VRAM sposta radicalmente le dinamiche d'acquisto aziendali, permettendo l'utilizzo di configurazioni hardware decisamente più contenute e accessibili.

Per garantire un elevatissimo throughput in grado di processare interazioni agentiche multiple alla massima velocità possibile, l'installazione ottimale è rappresentata da un nodo server equipaggiato con **2 GPU NVIDIA H100 80 GB** (160 GB di VRAM aggregata). Qualora il vincolo principale del progetto risiedesse nell'ottimizzazione pura dei costi per carichi di lavoro non sensibili alla latenza critica, si potrebbe optare per **2 GPU NVIDIA A100 80 GB** o persino **4 GPU NVIDIA L40S da 48 GB** (totale 192 GB). L'uso della scheda L40S, basata su architettura Ada Lovelace e memoria GDDR6, pur non offrendo la banda passante estrema della memoria HBM, risulta economicamente vantaggioso e sufficiente per i requisiti modesti di un modello a 8 miliardi di parametri distribuiti tramite layer PCIe.[33]

Per quanto attiene la RAM di Sistema dell'host, applicando metodicamente il rapporto di espansione matematica di $1.5x$ sui pesi isolati [9]:

$$RAM_{sistema} \geq 1.5 \times 16 \text{ GB} = 24 \text{ GB}$$

Nonostante la matematica ristretta calcoli una base minima di soli 24 GB, a causa del pesante footprint dovuto all'esecuzione di 20 instanze parallele di processi daemon appartenenti al framework agentico operativo (i summenzionati LangChain o CrewAI), una configurazione standard industriale e protetta da **128 GB di RAM DDR5** assicurerà zero rallentamenti lato host e fluidità assoluta per le operazioni di I/O disco.[37]

Termodinamica del Data Center: Calcolo del Consumo, Calore e Temperature

L'implementazione fisica e l'installazione di infrastrutture hardware dedicate all'IA con simili livelli di densità computazionale comportano l'inserimento di variabili ambientali estremamente critiche. L'architettura server si scontra frontalmente con l'equazione fondamentale della termodinamica applicata agli impianti HVAC (Heating, Ventilation, and Air Conditioning) dei data center: tutto il consumo elettrico immenso assorbito dai chip al silicio viene convertito in un identico volume di calore sensibile in uscita.[39] Tale calore deve essere immediatamente rimosso attraverso imponenti volumi d'aria o liquido refrigerante.[40]

La convenzione termodinamica standardizzata, supportata dalle linee guida ASHRAE (American

Society of Heating, Refrigerating and Air-Conditioning Engineers), stabilisce che 1 Watt di consumo elettrico puro genera approssimativamente 3,412 BTU/h (British Thermal Units per ora) di energia termica dissipata.[41]

La formula ingegneristica cardine per determinare il flusso e la spinta d'aria necessari per estrarre questo calore dal server, misurato in CFM (Cubic Feet per Minute - Piedi Cubi al Minuto) basandosi sul metodo scientifico dell'innalzamento di temperatura (Temperature Rise Method), è definita come:

$$CFM = \frac{Q_{BTU}}{1.08 \times \Delta T} = \frac{W \times 3.414}{1.08 \times \Delta T}$$

All'interno di questa vitale equazione meccanica:

- La variabile W rappresenta il consumo energetico totale del sistema in Watt misurato all'alimentatore.
- Il denominatore costante 1.08 è un fattore termodinamico complesso derivato specificamente dalla moltiplicazione tra i minuti in un'ora (60), la densità standard dell'aria al livello del mare (0,075 libbre per piede cubo) e il calore specifico intrinseco dell'aria asciutta (0,24 BTU per libbra per grado Fahrenheit).[40]
- La variabile ΔT rappresenta l'imprescindibile salto termico, ovvero la differenza oggettiva di temperatura in gradi Fahrenheit tra l'aria fresca immessa nel corridoio freddo (cold aisle) all'ingresso del rack server, e l'aria rovente espulsa nel corridoio caldo (hot aisle) dalla parte posteriore delle GPU.[40]

Le rigorose specifiche internazionali ASHRAE (Standard di Classe A1) raccomandano tassativamente che la temperatura dell'aria all'ingresso del server si mantenga tra i 18°C (64,4°F) e i 27°C (80,6°F). Il superamento prolungato di questi limiti costringe i sensori delle ventole ad aumentare i giri (RPM) alle massime velocità, peggiorando inesorabilmente l'efficienza energetica e rischiando il degrado prematuro dei fragili componenti al silicio.[44] Ai fini progettuali di ingegneria dell'impianto, si assume convenzionalmente un ΔT ottimizzato e stabile di $20^\circ\mathrm{F}$ (equivalente a circa $11,1^\circ\mathrm{C}$).[40]

Analisi Termica e di Raffreddamento per il Cluster 70B (8x H100)

L'analisi dell'assorbimento di un cluster di punta rivela dati allarmanti. Una singola unità GPU NVIDIA H100 SXM, operante a pieno carico per accelerare i pesanti tensori di calcolo dell'intelligenza artificiale, possiede un Thermal Design Power (TDP) di picco pari a 700W.[11] Il solo carico termico sprigionato dal comparto GPU si attesta a ben $8 \times 700\mathrm{W} = 5.600\mathrm{W}$. Aggiungendo a questa somma il massiccio assorbimento dei doppi processori host di classe enterprise (Intel Xeon Platinum o AMD EPYC ad alta densità), dei colossali banchi di RAM di

sistema DDR5, degli hard disk NVMe, e dei moduli switch interni NVSwitch che gestiscono le comunicazioni inter-GPU, il server nella sua interezza consumerà e dissiperà termicamente circa 7.000W ($7\ \text{kW}$) in condizioni di stress operativo elevato.[46]

Applicando la formula termodinamica per calcolare il flusso CFM d'aria forzata necessario per scongiurare la fusione dei circuiti:

$$CFM = \frac{7000 \times 3.414}{1.08 \times 20} = \frac{23.898}{21,6} \approx 1.106\ \text{CFM}$$

Questo risultato espone un fatto fisico ineluttabile: un singolo blocco hardware necessita di aspirare ed espellere violentemente oltre 1.100 piedi cubi di aria al minuto solo per mantenere le temperature operative sicure.[43] Data l'imponente e assordante pressione statica necessaria per forzare tale densità gassosa attraverso le micro-lamelle di dissipazione in un ristretto formato rack, la configurazione d'aria forzata a $7\ \text{kW}$ in uno spazio così concentrato raggiunge e talvolta supera i limiti estremi della termofluidodinamica dell'aria. Per questa irremovibile ragione fisica, lo standard per le infrastrutture che ospitano i giganteschi cluster basati sulla serie H100 sta rapidamente migrando verso tecnologie avanzate di raffreddamento a liquido diretto al chip (Direct Liquid Cooling, DLC). L'utilizzo di speciali piastre fredde per CPU e GPU governate da sofisticate unità di distribuzione refrigerante (Coolant Distribution Units, CDU) assicura una riduzione drammatica delle temperature operative, consentendo di evitare il temuto throttling termico – un rallentamento forzato automatico delle frequenze di clock hardware progettato per prevenire guasti catastrofici.[47]

Analisi Termica e di Raffreddamento per il Cluster 8B (2x A100 / H100)

Lo scenario si ridimensiona in modo drastico quando si analizza il consumo e la termodinamica della configurazione destinata all'inferenza del modello da 8 miliardi di parametri. Valutando un'architettura più bilanciata e basata su un duetto di GPU NVIDIA A100 da 80GB (con un Thermal Design Power più mite di 400W ciascuna), l'assorbimento massimo teorico dei core logici si arresta a 800W.[26] Computando prudenzialmente la presenza dei restanti componenti di calcolo dell'host, il server genererà un carico termico massimo di circa 1.400W ($1,4\ \text{kW}$).[46]

Applicando nuovamente l'equazione termica al diminuito carico in Watt:

$$CFM = \frac{1400 \times 3.414}{1.08 \times 20} = \frac{4.779,6}{21,6} \approx 221\ \text{CFM}$$

Questo specifico e limitato volume d'aria fresca in ingresso può essere gestito con assoluta disinvoltura dalle potenti ventole assiali integrate nei classici chassis industriali montati a rack, capaci di operare a regimi di rotazione compresi tra 6.000 e 12.000 RPM per garantire una

pressione statica perforante e direzionale.[50] Tale maneggevolezza termica consente l'installazione immediata, priva di imponenti ristrutturazioni strutturali o retrofit idraulici per liquid cooling, all'interno di virtualmente qualsiasi sala macchine preesistente o infrastruttura colocation tradizionale.[47]

Sistema AI	Carico Termico Approssimativo (W)	Calore Dissipato (BTU/h)	Raffreddamento Aria Richiesto (CFM con ΔT = 20°F)	Soluzione Termica Raccomandata
70B (8x H100)	~7.000 W	~23.898 BTU/h	~1.106 CFM	Direct Liquid Cooling (DLC) e unità CDU in rack densi.[48]
8B (2x A100)	~1.400 W	~4.780 BTU/h	~221 CFM	Raffreddamento standard ad aria forzata con chassis industriale.[50]

Analisi Economica dei Consumi Elettrici: Scenario Lombardia 2026

Il dispiegamento in produzione dell'hardware d'intelligenza artificiale estende l'analisi finanziaria ben oltre l'elevata spesa fissa in conto capitale (CAPEX) necessaria per l'acquisto iniziale dei costosi acceleratori grafici, per abbracciare l'imponente emorragia mensile delle spese operative correnti (OPEX), dominate dai costi di approvvigionamento dell'energia. Per calcolare con esattezza scientifica il costo reale e tangibile sopportato su base mensile da una società o data center posizionato nella regione Lombardia, in uno scenario temporale riferito al 2026, si deve estendere il calcolo di potenza introducendo una metrica fondamentale: il PUE (Power Usage Effectiveness).[52]

Il coefficiente PUE è l'indicatore principe per quantificare l'efficienza sistemica reale di un intero data center, definendo quanta energia venga irrimediabilmente dispersa dagli impianti di condizionamento climatico e dai sistemi di alimentazione ausiliaria o backup (UPS) rispetto all'elettricità che giunge effettivamente utile ai processori.

$$PUE = \frac{\text{Energia Totale Impianto (Raffreddamento, Luci, UPS, Server)}}{\text{Energia Esclusiva Apparati IT}}$$

A livello mondiale, il PUE medio delle infrastrutture oscilla storicamente intorno al valore di 1,56. Ciononostante, i grandi data center europei di concezione moderna (es. hyperscaler e installazioni colocation avanzate sul territorio lombardo e nel Nord Europa) sfoggiano indici ampiamente ottimizzati e conformi ai severi dettami normativi dell'Unione Europea in materia di sostenibilità e rendimento energetico, esibendo un PUE racchiuso nella forbice tra 1,20 e 1,30.[52] Nelle proiezioni e calcolazioni che seguono, applicheremo scientificamente un moltiplicatore PUE di 1,30. Questo indicatore rappresenta il valore di efficienza reale e plausibile di una struttura tecnologica avanzata che un'impresa media lombarda potrebbe noleggiare nel 2026.[56]

L'ammontare economico puro è derivato dall'incrocio tra i consumi e le tariffe del libero mercato energetico italiano, regolate e censite dalla medesima autorità pubblica ARERA. Ipotizzando e simulando l'adozione di un piano tariffario dedicato alle utenze business, l'indice PUN (Prezzo Unico Nazionale) aggiornato al mese di aprile 2026 stabilisce un costo netto per l'impresa (costituito dal prezzo della materia prima pura addizionato ai selettivi oneri di dispacciamento) collocato a circa **0,158 €/kWh** (equivalenti a circa 15,8 centesimi di Euro per ogni singolo kilowattora bruciato).[58] I complessi flussi software dei framework agentici lavorano in background per la risoluzione autonoma di algoritmi su base continua e non sorvegliata, mantenendo la linea di carico del data center sostanzialmente piatta 24 ore su 24, rendendo l'approccio contrattuale a prezzo fisso monorario il modello matematicamente e strategicamente più adeguato.[58]

Calcoli Elettrici ed Economici per l'Infrastruttura del Modello 70B

L'imponente hardware dimensionato per supportare agilmente il worst-case del modello a 70 miliardi di parametri necessita di 7 kW teorici per operare ai propri limiti massimi assoluti. Tuttavia, in una configurazione di esercizio agentico continuato nel mondo reale, l'assorbimento medio effettivo fluttua. A causa dei millisecondi di latenza per il recupero dati dalla rete, dei micro-cicli di inattività (idle time) fra la stesura di un passo del ragionamento (Chain-of-Thought) e il successivo recupero documentale tramite strumenti integrati, il carico medio della CPU e delle GPU può essere valutato e stimato a un robusto 80% del Thermal Design Power nominale teorico dell'intero rack.[48]

- **Potenza IT media assorbita nei circuiti:** $7\ \text{kW} \times 0.8 = 5,6\ \text{kW}$.
- **Potenza reale calcolata al contatore generale del data center (applicando il PUE del condizionamento termico):** $5,6\ \text{kW} \times 1,3 = 7,28\ \text{kW}$.

Energia elettrica consumata costantemente in un mese solare di esercizio (mediamente 730 ore):

$$E_{mese} = 7,28 \text{ kW} \times 730 \text{ h} = 5.314,4 \text{ kWh}$$

Il calcolo economico risultante traduce l'assorbimento in costi vivi e quantificabili aziendali:

$$C_{mese} = 5.314,4 \text{ kWh} \times 0,158 \text{ €/kWh} \approx 839,67 \text{ Euro al mese}$$

Il mantenimento energetico perpetuo di un singolo blocco logico di server, capace di reggere l'imponente carico cognitivo e la strabordante KV Cache per l'esecuzione del peggiore dei casi su 20 utenti concorrenti, si traduce in una fattura puramente elettrica vicina agli 840 Euro mensili.[58] Questa quota ingente copre tassativamente il solo esborso per gli elettroni mossi dalla rete e rigettati come aria calda, scorporando interamente i monumentali esborsi iniziali per i milioni di euro delle GPU H100, i canoni d'affitto degli spazi sicuri all'interno della struttura colocation e gli ammortamenti sull'hardware idraulico del liquid cooling.[47]

Calcoli Elettrici ed Economici per l'Infrastruttura del Modello 8B

Ripetendo parallelamente il medesimo esercizio finanziario sull'hardware dimensionato per contenere e processare il modello da 8 miliardi di parametri, il carico massimo calcolato tocca una vetta di 1,4 kW, la quale si comprime a una potenza operativa media di circa $1,12 \text{ kW}$ tramite la medesima assunzione dell'80% di carico.

- **Potenza reale calcolata al contatore generale del data center (con PUE):** $1,12 \text{ kW} \times 1,3 = 1,456 \text{ kW}$.

Energia elettrica consumata mensilmente (730 ore):

$$E_{mese} = 1,456 \text{ kW} \times 730 \text{ h} = 1.062,88 \text{ kWh}$$

Il calcolo economico risultante attesta i costi vivi per l'approvvigionamento e il condizionamento:

$$C_{mese} = 1.062,88 \text{ kWh} \times 0,158 \text{ €/kWh} \approx 167,93 \text{ Euro al mese}$$

Infrastruttura e Modello	**Potenza IT Nominale**	**Energia Totale Mensile (con PUE 1.30 e Carico 80%)**	**Costo Energia (€/kWh, ARERA 2026)**	**Spesa Elettrica OPEX Mensile (Lombardia)**

Server AI per Modello 70B	7.000 W	~5.314 kWh	0,158 €	**~840 Euro**
Server AI per Modello 8B	1.400 W	~1.063 kWh	0,158 €	**~168 Euro**

Il ricorso a mini-agenti reattivi, governati e mossi dal modello a 8B, abbatte prepotentemente i costi operativi continui legati ai consumi di un fattore quasi pari a 5, profilandosi come la decisione strategica, architetturale e logica di maggior rilevanza finanziaria laddove i flussi operativi non domandino imperativamente le inarrivabili capacità predittive, il reasoning astratto superiore e la profonda sapienza globale incapsulata in un colosso da 70 miliardi di connessioni neurali.[56]

Sintesi Conclusiva e Raccomandazioni Architetturali

La matematica sistemica ed ingegneristica alla base dei complessi ecosistemi d'intelligenza artificiale restituisce la visione di un panorama tecnologico in cui il calcolo hardware travalica ampiamente i banali conteggi dei soli parametri del silicio logico. L'architettura dei sistemi agenti in ambiente di produzione aziendale costringe a fondere teorie probabilistiche (M/G/1 queueing), limiti asintotici di latenza, algebra lineare applicata alla memoria, complessi teoremi di termofluidodinamica e bilanci di potenza PUE.[2] Le analisi analitiche qui condotte dimostrano incontrovertibilmente i requisiti inamovibili per sostenere con stabilità matematica e termica il dimensionamento peggiore garantito per 20 utenti.

L'approccio implementativo più robusto per l'integrazione enterprise del modello di punta da 70B impone, a fronte dei 360 GB combinati di pesi FP16 e gigantesca KV Cache, il dispiegamento immediato e compatto di un nodo massiccio: **8 GPU NVIDIA H100 interconnesse tramite la formidabile dorsale NVLink (per un totale di 640 GB di VRAM), dirette da un comparto RAM host da 512 GB o superiore**.[9] Un sistema di tale densità scatena immediate complicanze termiche per smaltire l'inferno di calore generato dai 7.000 W continui, richiedendo oltre 1.100 CFM di spostamento d'aria e forzando spesso la struttura all'implementazione ingegneristica del raffreddamento a liquido.[26] L'esborso in termini termici e operativi porta inevitabilmente i soli oneri di bolletta elettrica ad assestarsi in Lombardia su quote prossime agli 840 Euro mensili a server, senza alcuna indicazione di calo sulle proiezioni future del mercato energetico.[56]

Specularmente, la decostruzione matematica e architetturale dei "mini-agenti", incarnati dall'architettura snella a 8 miliardi di parametri con l'avanzata tecnologia GQA (Grouped-Query Attention), attenua la fame inesausta della cache di attenzione, abbassando la richiesta teorica

dinamica a livelli scalabili e gestibili dal mercato. L'alloggiamento su sole **2 GPU NVIDIA H100 (o alternativamente A100 per severa ottimizzazione di cassa) per un ammontare totale di 160 GB VRAM, fiancheggiato da soli 128 GB di memoria di sistema** protegge da colli di bottiglia latenti a un decimo dell'impatto economico totale. I consumi energetici, drasticamente amputati a circa 1.400 W lordi, sono raffreddabili pacificamente dalla convenzionale aria forzata, e implicano costi operativi OPEX limati sotto i 170 Euro mensili per unità installata.[50]

Il calcolo matematico non può esimersi da un avvertimento sistemico terminale ai decisori infrastrutturali aziendali. Il difetto progettuale predominante nei team d'integrazione AI non risiede nel calcolo grossolano della pura potenza aritmetica FLOPs, ma nella fatale distorsione prospettica, spesso colpevolmente in difetto, circa la voracità spaziale esplosiva e scalare posseduta dalla KV Cache nei contesti agentici.[5] Le equazioni indagate certificano un vincolo ferreo di fisica applicata in cui la fluida brillantezza e la cognizione stocastica del software IA dipendono inevitabilmente e inesorabilmente dall'eliminazione metodica dei colli di bottiglia termo-idraulici e dalla meticolosa algebra della larghezza di banda dell'hardware sottostante.[21]

Bibliografia

1. NVIDIA Rubin CPX Platform Powering the Next Era of Agentic AI and Autonomous Computing, accesso eseguito il giorno aprile 29, 2026, https://www.analyticsinsight.net/artificial-intelligence/nvidia-rubin-cpx-platform-powering-the-next-era-of-agentic-ai-and-autonomous-computing
2. VRAM Requirements in Agentic AI Systems: A Comprehensive Guide - AWS Builder Center, accesso eseguito il giorno aprile 29, 2026, https://builder.aws.com/content/31Yeh8Jz9yCtgz9uL6lseoUQpLB/vram-requirements-in-agentic-ai-systems-a-comprehensive-guide
3. Effects of Dynamic Agentic Workflows on High-Performance Storage - WWT, accesso eseguito il giorno aprile 29, 2026, https://www.wwt.com/blog/effects-of-dynamic-agentic-workflows-on-high-performance-storage
4. A guide to LLM inference and performance - Baseten, accesso eseguito il giorno aprile 29, 2026, https://www.baseten.co/blog/llm-transformer-inference-guide/
5. Estimating LLM Inference Memory Requirements | by NJ Raman - Medium, accesso eseguito il giorno aprile 29, 2026, https://medium.com/@nraman.n6/estimating-llm-inference-memory-requirements-3ab599b7284b
6. Estimating LLM Inference Memory Requirements | by Kyle Bell - Medium, accesso eseguito il giorno aprile 29, 2026, https://medium.com/@kylebell_70950/estimating-llm-inference-memory-requirements-fa9523fb4808
7. Calculating GPU memory for serving LLMs | LLM Inference Handbook - BentoML, accesso eseguito il giorno aprile 29, 2026, https://bentoml.com/llm/getting-started/calculating-gpu-memory-for-llms
8. Calculating GPU Requirements for Efficient LLAMA 3.1 70B Deployment on AWS Sagemaker - IBM Community, accesso eseguito il giorno aprile 29, 2026,

https://community.ibm.com/community/user/blogs/arindam-dasgupta/2024/09/18/calculating-gpu-requirements-for-efficient-llama-3
9. Self-Hosting LLaMA 3.1 70B (or any ~70B LLM) Affordably | by Abhinand | Medium, accesso eseguito il giorno aprile 29, 2026, https://abhinand05.medium.com/self-hosting-llama-3-1-70b-or-any-70b-llm-affordably-2bd323d72f8d
10. Llama 3.1 - 405B, 70B & 8B with multilinguality and long context - Hugging Face, accesso eseguito il giorno aprile 29, 2026, https://huggingface.co/blog/llama31
11. H100 GPU - NVIDIA, accesso eseguito il giorno aprile 29, 2026, https://www.nvidia.com/en-us/data-center/h100/
12. Should I run Llama 70B on an NVIDIA H100 or A100? | AI FAQ - Jarvis Labs, accesso eseguito il giorno aprile 29, 2026, https://jarvislabs.ai/ai-faqs/should-i-run-llama-70b-on-an-nvidia-h100-or-a100
13. Build with DeepSeek V4 Using NVIDIA Blackwell and GPU-Accelerated Endpoints | NVIDIA Technical Blog, accesso eseguito il giorno aprile 29, 2026, https://developer.nvidia.com/blog/build-with-deepseek-v4-using-nvidia-blackwell-and-gpu-accelerated-endpoints/
14. Llama3.1 inference memory requirements · Issue #2345 · huggingface/blog - GitHub, accesso eseguito il giorno aprile 29, 2026, https://github.com/huggingface/blog/issues/2345
15. Llama 3.1 8B: Specifications and GPU VRAM Requirements - ApX Machine Learning, accesso eseguito il giorno aprile 29, 2026, https://apxml.com/models/llama-3-1-8b
16. meta-llama/Llama-3.1-8B - Hugging Face, accesso eseguito il giorno aprile 29, 2026, https://huggingface.co/meta-llama/Llama-3.1-8B
17. Under the Hood of Llama 3.1 70B Distributed Inference | by Subrata Goswami - Medium, accesso eseguito il giorno aprile 29, 2026, https://whatdhack.medium.com/under-the-hood-of-llama-3-1-70b-distributed-inference-8b3c03886f22
18. GPU Memory Requirements for LLMs: VRAM Calculator | Spheron Blog, accesso eseguito il giorno aprile 29, 2026, https://www.spheron.network/blog/gpu-memory-requirements-llm/
19. Which AI Agent Framework Should You Choose? LangChain vs LlamaIndex vs AutoGen vs CrewAI for Enterprise (2026) | TechAhead, accesso eseguito il giorno aprile 29, 2026, https://www.techaheadcorp.com/blog/top-agent-frameworks/
20. Do you find agent frameworks like Langchain, crew, agno actually useful? - Reddit, accesso eseguito il giorno aprile 29, 2026, https://www.reddit.com/r/AI_Agents/comments/1mm73hz/do_you_find_agent_frameworks_like_langchain_crew/
21. A Queueing Theoretic Perspective on Low-Latency LLM Inference with Variable Token Length - arXiv, accesso eseguito il giorno aprile 29, 2026, https://arxiv.org/html/2407.05347v2
22. [Literature Review] A Queueing Theoretic Perspective on Low-Latency LLM Inference with Variable Token Length - Moonlight | AI Colleague for Research Papers, accesso eseguito il giorno aprile 29, 2026,

https://www.themoonlight.io/en/review/a-queueing-theoretic-perspective-on-low-latency-llm-inference-with-variable-token-length
23. Queueing, Predictions, and Large Language Models: Challenges and Open Problems | Stochastic Systems - PubsOnLine, accesso eseguito il giorno aprile 29, 2026, https://pubsonline.informs.org/doi/10.1287/stsy.2025.0106
24. Queueing Theory for LLM Inference - DZone, accesso eseguito il giorno aprile 29, 2026, https://dzone.com/articles/queueing-theory-for-llm-inference
25. SambaNova's Dataflow Architecture: The natural Flow of AI, accesso eseguito il giorno aprile 29, 2026, https://datacentremagazine.com/news/sambanovas-dataflow-architecture-the-natural-flow-of-ai
26. Benchmarking NVIDIA GPU Throughput for LLMs and Understanding GPU Configuration Choices in the AI Space | Dell Technologies Info Hub, accesso eseguito il giorno aprile 29, 2026, https://infohub.delltechnologies.com/de-de/p/benchmarking-nvidia-gpu-throughput-for-llms-and-understanding-gpu-configuration-choices-in-the-ai-space/
27. LLM Inference Performance Engineering: Best Practices | Databricks Blog, accesso eseguito il giorno aprile 29, 2026, https://www.databricks.com/blog/llm-inference-performance-engineering-best-practices
28. Mind the Memory Gap: Unveiling GPU Bottlenecks in Large-Batch LLM Inference - arXiv, accesso eseguito il giorno aprile 29, 2026, https://arxiv.org/html/2503.08311v2
29. Introducing Llama 3.1: Our most capable models to date - Meta AI, accesso eseguito il giorno aprile 29, 2026, https://ai.meta.com/blog/meta-llama-3-1/
30. bridge.models.llama.llama_provider — Megatron Bridge - NVIDIA Documentation, accesso eseguito il giorno aprile 29, 2026, https://docs.nvidia.com/nemo/megatron-bridge/0.3.1/apidocs/bridge/bridge.models.llama.llama_provider.html
31. Llama 3.1 70B: Specifications and GPU VRAM Requirements - ApX Machine Learning, accesso eseguito il giorno aprile 29, 2026, https://apxml.com/models/llama-3-1-70b
32. LLaMA 3.1 8B Model Overview - Emergent Mind, accesso eseguito il giorno aprile 29, 2026, https://www.emergentmind.com/topics/llama-3-1-8b-model-2348e96d-21f2-48dc-88c2-90e5888c626b
33. LLM Inference Sizing and Performance Guidance - VMware Cloud Foundation (VCF) Blog, accesso eseguito il giorno aprile 29, 2026, https://blogs.vmware.com/cloud-foundation/2024/09/25/llm-inference-sizing-and-performance-guidance/
34. Lenovo LLM Sizing Guide, accesso eseguito il giorno aprile 29, 2026, https://lenovopress.lenovo.com/lp2130-lenovo-llm-sizing-guide
35. Comparing NVIDIA's Top AI GPUs H100, A100, A6000, and L40S - NADDOD Blog, accesso eseguito il giorno aprile 29, 2026, https://www.naddod.com/blog/comparing-nvidia-top-ai-gpus-h100-a100-a6000

-and-l40s
36. NVIDIA H100 vs H200: Benchmarks, Specs, and Performance Comparison for AI Inference, accesso eseguito il giorno aprile 29, 2026, https://www.spheron.network/blog/nvidia-h100-vs-h200/
37. Can anyone show the speedtest of TESLA A100 and TESLA H100? : r/LocalLLaMA - Reddit, accesso eseguito il giorno aprile 29, 2026, https://www.reddit.com/r/LocalLLaMA/comments/1fapu2g/can_anyone_show_the_speedtest_of_tesla_a100_and/
38. How much ram to run llama3.1 70b? : r/LocalLLaMA - Reddit, accesso eseguito il giorno aprile 29, 2026, https://www.reddit.com/r/LocalLLaMA/comments/1gi4bu1/how_much_ram_to_run_llama31_70b/
39. Calculating potential heat output of GPUs : r/EtherMining - Reddit, accesso eseguito il giorno aprile 29, 2026, https://www.reddit.com/r/EtherMining/comments/ax7of7/calculating_potential_heat_output_of_gpus/
40. HVAC Formulas and Calculations Field Reference Guide for Technicians: CFM, BTU, Cv, GPM, ΔT, and More | Belimo, accesso eseguito il giorno aprile 29, 2026, https://www.belimo.com/ca/en_US/blog/hvac-formulas-and-calculations-guide
41. Measuring Airflow Using Temperature Rise Method - Mingledorff's, accesso eseguito il giorno aprile 29, 2026, https://www.mingledorffs.com/measuring-airflow-using-temperature-rise-method/
42. Better Temperature Measurements - HVAC School, accesso eseguito il giorno aprile 29, 2026, http://www.hvacrschool.com/better-temperature-measurements/
43. The 4 Delta T's of Data Center Cooling: What You're Missing - Upsite Technologies, accesso eseguito il giorno aprile 29, 2026, https://www.upsite.com/blog/the-4-delta-ts-of-data-center-cooling-what-youre-missing/
44. Server Room Temperature Standards: ASHRAE Guide and Ideal Values - Birtech, accesso eseguito il giorno aprile 29, 2026, https://www.birtech.com/en/blog/environmental-monitoring/server-room-temperature-ASHRAE-standard
45. Equipment Thermal Guidelines for Data Processing Environments - ASHRAE, accesso eseguito il giorno aprile 29, 2026, https://xp20.ashrae.org/datacom1_4th/ReferenceCard.pdf
46. How do I calculate the total heat generated by multiple NVIDIA GPUs in a rack-mounted edge AI system? - Massed Compute, accesso eseguito il giorno aprile 29, 2026, https://massedcompute.com/faq-answers/?question=How%20do%20I%20calculate%20the%20total%20heat%20generated%20by%20multiple%20NVIDIA%20GPUs%20in%20a%20rack-mounted%20edge%20AI%20system?
47. DATA CENTER - Assoimmobiliare, accesso eseguito il giorno aprile 29, 2026, https://www.assoimmobiliare.it/wp-content/uploads/2024/03/Colliers_Data-Center-Snapshot-2024_Italy__.pdf

48. Key Insight: “100% GPU Util” ≠ “100% Heat” | by ProphetStor | Medium, accesso eseguito il giorno aprile 29, 2026, https://prophetstor.medium.com/key-insight-100-gpu-util-100-heat-27d8ab39adf3
49. 4 Critical Insights for Ordering Data Center Liquid Cooling Systems - Chilldyne, accesso eseguito il giorno aprile 29, 2026, https://chilldyne.com/4-critical-insights-for-ordering-data-center-liquid-cooling-systems/
50. Heatwave 2025: CPU & GPU Temperature Monitoring Guide - Unihost.com Blog, accesso eseguito il giorno aprile 29, 2026, https://unihost.com/blog/server-temperature-monitoring-guide-2025/
51. Guidelines for the implementation of Data Centers | ADVANT Nctm, accesso eseguito il giorno aprile 29, 2026, https://www.advant-nctm.com/en/news/linee-guida-per-la-realizzazione-dei-data-center
52. Power usage effectiveness - Google Data Centers, accesso eseguito il giorno aprile 29, 2026, https://datacenters.google/efficiency
53. Europe Data Centre Power Demand | ICIS, accesso eseguito il giorno aprile 29, 2026, https://www.icis.com/explore/resources/data-centres-hungry-for-power/
54. Towards Planet Proof Computing: Law and Policy of Data Centre Sustainability in the European Union | Technology and Regulation, accesso eseguito il giorno aprile 29, 2026, https://techreg.org/article/download/19844/24487/56761
55. The EU's Energy Efficiency Directive and Its Impact on Datacenters - September 2025 - Covington & Burling LLP, accesso eseguito il giorno aprile 29, 2026, ww.mckinsey.com/industries/technology-media-and-telecommunications/our-insights/the-cost-of-compute-a-7-trillion-dollar-race-to-scale-data-centershttps://www.cov.com/-/media/files/corporate/publications/2025/04/the-eus-energy-efficiency-directive-and-its-impact-on-datacenters.pdf
56. Energy and WEEE, data centres are at the forefront of a circular economy - Ecomondo, accesso eseguito il giorno aprile 29, 2026, https://www.ecomondo.com/en/news-detail/energy-and-weee-data-centres-are-at-the-forefront-of-a-circular-economy?newsId=5839395
57. European Data Centres - Savills, accesso eseguito il giorno aprile 29, 2026, https://pdf.euro.savills.co.uk/european/european-commercial-markets/spotlight-european-data-centres---may-2024.pdf
58. Costo kWh: qual è il prezzo dell'energia elettrica oggi? | Segugio.it, accesso eseguito il giorno aprile 29, 2026, https://tariffe.segugio.it/guide-e-strumenti/domande-frequenti/quanto-costa-un-kwh-di-energia-elettrica.aspx
59. PUN - Prezzo Unico Nazionale energia elettrica | Luce e Gas Italia, accesso eseguito il giorno aprile 29, 2026, https://luceegasitalia.it/indici-pun-e-psv/pun/
60. Indice PUN: Valori e Tariffe Gas Servizio di Tutela | A2A Energia, accesso eseguito il giorno aprile 29, 2026, https://www.a2a.it/assistenza/tutela-cliente/indici/indice-pun
61. Addressing AI's Power Consumption Challenges Fujitsu's Three Energy-Saving

Technologies | Fujitsu Global, accesso eseguito il giorno aprile 29, 2026, https://global.fujitsu/en-global/insight/tl-3power-saving-technologies-20250529
62. Italy Electricity Price - Quote - Chart - Historical Data - News - Trading Economics, accesso eseguito il giorno aprile 29, 2026, https://tradingeconomics.com/italy/electricity-price
63. North America Data Center Trends H1 2025 - CBRE, accesso eseguito il giorno aprile 29, 2026, https://www.cbre.com/insights/reports/north-america-data-center-trends-h1-2025
64. Electricity prices around the world | GlobalPetrolPrices.com, accesso eseguito il giorno aprile 29, 2026, https://www.globalpetrolprices.com/electricity_prices/
65. The cost of compute: A $7 trillion race to scale data centers - McKinsey, accesso eseguito il giorno aprile 29, 2026, https://w